

期末课程设计

成绩占比：占期末总成绩的 15%

考核要求：能够以个人或者小组（2-3 人）完成一个小型工程实践课题。具体要求如下：

- （1）能够选用合适的开发工具、综合运用所学专业知识和技能编写应用程序。
- （2）能够根据实际问题，对开发环境进行配置。
- （3）根据实际需求，设计并完成综合实践课题。
- （4）能够根据课程要求，通过文字、图、表的形式撰写课题报告，并进行相关分析。
- （5）能够按照要求，按时完成课程设计任务，并养成良好的职业习惯。

以下三个题目，任选一个完成。

说明：

- （1）题目一和题目二，既可以以小组为单位完成，又可以以个人为单位完成。题目三，仅可以以个人为单位完成。
- （2）无论以个人为单位，还是以小组为单位完成题目，每人都需要提交报告。如果以小组为单位完成题目，需要在报告中写明你本人具体做的工作，你的工作量将直接影响你的课程设计成绩。
- （3）如果你的期中项目是与基于决策树的西瓜分类问题相关的题目，建议你选择题目一或者题目二作为期末课程设计题目。否则，你需要采用与期中项目不同的方法完成题目三。

题目一：新闻分类研究

要求：

- （1）使用不少于两种机器学习模型训练分类器，如：朴素贝叶斯、SVM、FastText、TextCNN、TextRNN、TextRCNN、Transformer 等。
- （2）完成中文分词、停用词过滤、词向量化处理、模型训练，模型评价方法采用准确率（precision）、召回率（recall）和 F1 值，并从训练效率和模型精度两个角度，对所实现的模型进行比较分析。
- （3）课题报告需详细描述：数据处理的过程和方法，模型的基本定义、关键代码，训练集和测试集的模型精度等。

说明：

(1) 新闻文本分类采用 THUCNews 数据集，共 10 个类别，数据集具体内容见附件。

(2) 数据集文件说明：

train.txt – 训练集

dev.txt – 验证集


test.txt – 测试集

class.txt – 新闻类别，每行的中文标签对应训练集 0 - 9 的数字标签


embedding_SougouNews.npz – 基于搜狗新闻的预训练词嵌入模型

vocab.pkl – 词表

(3) 数据集样例：



示例 1 train.txt 文件内容，包含新闻标题和数字类别



示例 2 class.txt 文件内容，每行为一个类别，分别对应 train.txt 文件中的数组类别

题目二：电影评论情感分析研究

要求：

- (1) 使用不少于两种机器学习模型训练分类器，如：朴素贝叶斯、SVM、FastText、TextCNN、TextRNN、TextRCNN、Transformer 等。
- (2) 将原始评论数据集合理划分为训练集、验证集和测试集，对评论字段 comment 进行合适的中文文本处理，包括但不限于中文分词、停用词过滤、词向量化等，并将正负面情绪评分（pos_p）转换为正负面情绪标签。模型评价方法采用准确率（precision）、召回率（recall）和 F1 值，并从训练效率和模型精度两个角度，对所实现的模型进行比较分析。
- (3) 课题报告需详细描述：数据处理的过程和方法，模型的基本定义、关键代码，训练集和测试集的模型精度等。

说明：

- (1) 电影评论情感分析采用 MovieComments 数据集，数据集具体内容见附件。
- (2) 数据集文件说明：

data_clean.xlsx – 电影评论数据集

- (3) 数据集样例：

user_name	comment_voted	comment_voted	movie_star	comment_time	comment	pos_p	month	hour	week
海边的西米	2552	2552	40	2020-10-03 02:37:43	想看尔东升骂遍所有想露脸十八线男团idol	0.0029	10	2	5
DING	1242	1242	40	2020-10-03 12:12:00	太喜欢温峥嵘那种坐在B级却浑身上下散发出S级光芒的状态	0.9998	10	12	5
若谷	465	465	50	2020-10-02 23:01:18	他们四个批评人真的严厉又一针见血，尤其尔冬升导演，太	0.0014	10	23	4
Cycble	350	350	40	2020-10-03 08:11:46	①第一期就出现名场面“晏紫东彩旗接吻”“尔东升指	0.0018	10	8	5
PRAI	340	340	40	2020-10-02 21:08:38	不错，想看他们四个批人	0.9999	10	21	4
弗洛伊德之怒	118	118	40	2020-10-03 11:32:42	1.尔冬升导演的点评比儒学三连更切中要害 被他dis的半斤	0.0018	10	11	5
Foley	80	80	40	2020-10-03 14:39:57	尔冬升一个人拉高了这个节目的档次。	0.0028	10	14	0
松松松松呀	73	73	40	2020-10-02 22:59:36	马苏说五分钟的戏，怕观众get不到角色关系，害，怕不是	0.0013	10	22	4
吴亦凡	78	78	50	2020-10-03 01:48:25	为尔冬升导演打call！审美完全和他一致哈~	0.0016	10	1	5
静静的春天	60	60	50	2020-10-03 13:44:03	张大为啥要去这个节目，太违和了，零基础又没有悟性关键	0.0022	10	13	5
耿豆包	52	52	40	2020-10-03 01:16:48	尔导请多说实话	0.3332	10	1	5
万事想来都在朕	39	39	40	2020-10-03 03:04:04	尔东升导演6啊，李成儒老师期都在就好了。	0.0013	10	3	5
连宝	29	29	40	2020-10-10 21:44:46	最喜欢看郭敬明哔一大堆，其他人憋着“卧槽这个太傻x”	0.9999	10	21	5
今天吃火药了吗	18	18	40	2020-10-11 02:39:21	这季真的敢说啊，尔冬升导演直率又可爱，越来越喜欢李	0.9998	10	2	6
深夜的阿斯伯格	15	15	40	2020-10-04 22:46:30	尔冬升现在越看越像黄维德，坐等下期李诚儒手撕郭敬明！	0.0019	10	22	6

- (4) 关键数据字段说明：

user_name: 发表评论的用户名

comment_voted: 用户的历史投票总数

movie_star: 该条评论的用户评分

comment_time: 评论时间

comment: 评论内容

pos_p: 正负面情绪评分，取值为 0~1 之间的概率，分值越高越倾向正面

题目三：西瓜分类研究

要求：

- (1) 使用决策树算法对西瓜数据集进行分类，并最终形成一个完整的分类决策树。

(2) 课题报告需详细描述：数据处理的过程和方法，包括具体的计算过程，以及关键代码的实现过程。

说明：

- (1) 西瓜分类采用附件 PowerPoint 文件中的西瓜数据集。
- (2) 将西瓜数据集合理划分为训练集和测试集。
- (3) 数据集样例：

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	清晰	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

提交内容和时间：

- (1) 程序实现代码（需写明代码注释）需上传至学习通平台。
- (2) 程序运行演示视频需上传至学习通平台。
- (3) 报告采用学校统一的格式，其中，电子版报告上传至学习通平台，纸质版报告以班级为单位，收齐后提交至新综合楼 924 办公室（期中项目纸质版报告也同时一起提交）。
- (4) 以上材料提交时间为 2025 年 7 月 4 日（周五）下班前。

结语：

- (1) 三个题目的难度是不一样的，同学们可以根据自身的能力和兴趣选择适合的题目。
- (2) 关于题目三，本题目在授课过程中，已经反反复复讲授了多遍，设置本题目的目的是保证每位同学在不抄袭其他同学作业的情况下，也能顺利的完成期末课程设计。但是，我建议选择题目三的同学能够在题目基本要求的基础上，根据我上课时的建议多做一些内容。
- (3) 作为课程的授课教师，我知道每位同学的能力是有差异的，我也知道期末期间每位同学的时间都是很宝贵的。但是，同学们，你们都十分清楚的知道未来的职场是很

残酷的，你们可以把这次大作业当作是自己步入职场前的一次练兵，训练自己能够在有限的时间内，高效的完成任务。

（4）坚决杜绝同学之间相互抄袭作业，一旦发现，抄袭与被抄袭的同学都将最多评为60分（百分制）。